AI CLAIMS AGENT

Rapport technique - projet Deep Learning

Version de démonstration locale | 24 octobre 2026

Résumé exécutif

Le système reçoit une déclaration de sinistre et ses pièces (PDF, images et éventuellement audio). Il extrait des faits, observe les dommages visibles, recherche des passages contractuels puis calcule une recommandation explicable. Le périmètre est une aide au tri et à l'instruction : il ne verse pas d'indemnité et ne doit pas prendre une décision définitive lorsque le contrat individuel ou les preuves sont incomplets.

Périmètre

- Cas ciblé : sinistre automobile, avec un corpus de démonstration AXA France.
- Sorties : ACCEPT, INVESTIGATE ou REJECT, score de risque, confiance, motifs et références documentaires.
- Entrées : formulaire, PDF textuels, images du véhicule et audio transcrit en français.

Vue d'ensemble

React	Django / DRF	n8n	3 workers parallèles	Fraud	Decision	Callback

Intake et restitution sont des étapes de l'interface/API, pas des agents LLM autonomes. Les trois spécialistes indépendants tournent en parallèle; Fraud puis Decision attendent leurs résultats.

Point de prudence

Le corpus est constitué des Conditions générales publiques AXA France « Mon Auto », version septembre 2026. Il ne contient pas les Conditions particulières du client : une garantie individuelle ne peut donc pas être présumée acquise.

1. Choix des outils

La séparation des responsabilités privilégie une interface accessible, un backend métier testable et un orchestrateur visuel. Elle évite de confier au LLM la gestion des appels, des états ou des transitions de workflow.

Composant	Rôle dans le projet	Justification et limite
React + Vite	Formulaire de déclaration, dépôt de pièces, fiche dossier, timeline, contacts et traçabilité.	Itération rapide de l'interface. Le navigateur ne porte pas les règles de décision ni les secrets.
Django + DRF	API REST, modèles Claim/ClaimDocument/InsuranceContact, validation, persistance et endpoints d'agents.	ORM et serializers adaptés au prototype; les décisions sont stockées et l'API peut être testée indépendamment de n8n.
n8n	Webhook de départ, appels HTTP parallèles, fusion des résultats, séquence Fraud/Decision, callback.	Workflow lisible et démontrable. Dépend d'un service séparé et d'une configuration de webhook fiable.
PostgreSQL + Docker Compose	Base relationnelle et lancement coordonné de db, backend, frontend et n8n.	Répétabilité locale. Les identifiants livrés dans Compose sont de démonstration, jamais de production.
Ollama	Inférence locale pour extraction, vision et réponses RAG; embeddings locaux.	Réduit l'envoi des pièces à un fournisseur de LLM externe et les coûts d'API. Consomme les ressources de la machine et doit être évalué sur le matériel cible.
faster-whisper	Transcription de l'audio avant l'extraction des faits.	Modèle small, langue française, CPU/int8 dans la configuration observée. La qualité dépend du bruit, de l'accent et de la durée.

Pourquoi garder les règles métier dans Django

Le workflow orchestre les étapes, mais le calcul des règles, la validation des sorties et l'enregistrement restent côté backend. Cela rend les décisions reproductibles et permet de tester Fraud/Decision sans exécuter les modèles distants. Le callback n8n ne transporte que la décision structurée, les résultats des agents et un jeton de vérification.

2. Choix des modèles et multimodalité

Configuration locale observée dans .env au moment de la rédaction. Ce choix est pragmatique; le dépôt ne contient pas encore de benchmark comparatif entre plusieurs modèles.

Tâche	Modèle configuré	Pourquoi / rôle
Document Agent	qwen2.5:3b	Extraction structurée de dates, lieu, récit, police, parties, montant déclaré et pièces manquantes à partir du formulaire, du texte PDF et de la transcription.
Vision Agent	llava:7b	VLM local pour la présence des dommages, les zones et les observations visuelles. Les zones sont normalisées vers front/rear/left/right et variantes.
Policy/RAG Agent	qwen2.5:3b	Réponse en JSON limitée aux passages récupérés; classe la couverture en covered, excluded ou insufficient_information.
Embeddings RAG	nomic-embed-text:latest	Transforme chaque page et la requête en vecteur pour calculer la similarité cosinus. Ce n'est pas un modèle de génération.
Audio	faster-whisper small	Transcription en français, CPU, int8, puis texte transmis à Document Agent.

Mode de fusion

Le système réalise une fusion tardive (late fusion) : chaque modalité est d'abord analysée séparément; les sorties structurées sont ensuite réunies. Le texte du dossier, les observations visuelles et les extraits RAG sont fournis à Fraud/Decision. Il n'y a pas de CLIP/CLAP ni de modèle multimodal unique qui fusionne pixels, audio et contrat en une seule représentation.

Sorties contrôlées et replis

- Les appels Ollama utilisent une température nulle et des schémas Pydantic/JSON; les payloads de politique sont normalisés avant validation.

- Si Ollama échoue, des replis locaux existent. Le repli vision infère toutefois la zone depuis la description et ne détecte donc pas une vraie contradiction photo/texte.

- Le PDF textuel est extrait avec pypdf. Une reconnaissance OCR complète des PDF scannés et une analyse de mise en page ne sont pas démontrées dans le code actuel.

Trade-off

Les modèles locaux simplifient la confidentialité et rendent la démonstration autonome, mais leurs résultats peuvent être moins robustes qu'un service spécialisé. Le choix doit être confirmé par une évaluation sur un jeu de sinistres représentatif.

3. Approche RAG

Corpus et provenance

Le corpus est un PDF officiel public AXA France : Conditions générales « Mon Auto », version septembre 2026, 104 pages. Le manifeste local référence l'URL AXA et indique que les pages 5 à 103 sont indexées. Les Conditions particulières, les garanties réellement souscrites et les avenants ne sont pas présents.

Préparation et retrieval

Étape	Implémentation constatée
Découpage	Une page PDF devient un chunk; métadonnées : page, section estimée, assureur, version, source et URL. Texte par chunk tronqué à 12 000 caractères.
Requête	Récit + date + lieu, augmentés par une liste d'intentions : dommages au véhicule, collision, dommages tous accidents, responsabilité civile, exclusions.
Recherche	Avec Ollama : embeddings des pages et de la requête, cosinus, top 5. Calculs gardés en cache mémoire Python via lru_cache; pas de base vectorielle persistante.
Repli	Recherche lexicale simple avec mots communs et bonus pour les termes d'intention; elle renvoie des passages mais ne tranche pas la couverture.
Génération	Qwen reçoit les cinq passages et doit citer les pages. La consigne impose insufficient_information en cas d'absence des Conditions particulières ou de décalage pays/contrat.

Pourquoi cette approche

La page conserve la référence au numéro de page du contrat et forme un chunk stable, explicable et simple à vérifier à l'écran. Les métadonnées permettent de tracer la source. C'est un compromis adapté à un seul PDF de démonstration; l'absence de chevauchement ou de segmentation par article peut couper une garantie entre deux pages.

Limites et amélioration

- Évaluer page par page contre un découpage par articles/sections; mesurer Recall@5 et MRR sur 15-20 questions avec passages attendus.

- Ajouter des filtres assureur/pays/produit, déduplication, versionnage et vérification de citations; séparer CG et Conditions particulières.

- Remplacer le cache mémoire par un index persistant (par exemple pgvector) seulement si le corpus et le besoin le justifient.

La similarité ne prouve pas la couverture : le RAG retrouve une règle générale; il ne remplace ni le contrat individuel ni l'expert juridique.

4. Architecture des agents

n8n envoie trois branches indépendantes, puis attend les données nécessaires aux étapes aval. Cette orchestration hybride suit les dépendances réelles du dossier.

Étape	Entrées	Traitement / sortie	Ordre
Document	Formulaire, PDF textuel, transcription audio	Faits JSON, métadonnées des pièces, missing_documents, notes d'extraction.	Parallèle
Vision	Jusqu'à six photos	Dommages visibles, zones, type, sévérité, qualité et observations.	Parallèle
Policy/RAG	Récit + corpus AXA	Statut de couverture, pages référencées, informations manquantes et confiance du RAG.	Parallèle
Fraud	Faits Document + zones Vision + pièces manquantes	Risque pondéré et preuves. Incohérence avant/arrière : +50; pièce manquante : +25; plafond 100.	Après fusion
Decision	Statut RAG + risque + complétude + photos	ACCEPT / INVESTIGATE / REJECT, confiance, raisons et références.	Séquentiel

Pourquoi plusieurs agents, et pas un monolithe

Document, Vision et Policy consultent des sources différentes et peuvent travailler en parallèle, ce qui réduit la latence par rapport à une chaîne entièrement séquentielle. Fraud a besoin de leurs résultats croisés; Decision a besoin du risque calculé et du statut contractuel : ces deux étapes restent séquentielles. Les schémas structurés, le journal de timeline et les références rendent le parcours inspectable.

Ce qui est volontairement simple

- Fraud n'est pas un LLM : règles déterministes uniquement, actuellement deux règles actives. Le paramètre policy_result n'est pas encore utilisé par cette fonction.

- Decision n'est pas un LLM : toute exclusion explicite conduit à REJECT; une couverture inconnue ou tout risque non nul conduit à INVESTIGATE; sinon ACCEPT.

- Intake correspond au formulaire/API; Report correspond à la fiche et aux traces UI, pas à deux agents autonomes supplémentaires.

La recommandation n'est pas une décision de paiement ou de refus définitive. Les dossiers INVESTIGATE sont transmis au responsable choisi; la vérification humaine reste requise.

5. Évaluation du système

État actuel

Neuf tests unitaires sont définis dans backend/claims/tests.py. Ils couvrent le cas tunisien avec corpus AXA France, exclusion explicite, normalisation JSON, normalisation d'une zone visuelle, incohérence bidirectionnelle avant/arrière, propagation des preuves, création API et remplacement/suppression de pièces. Ils vérifient des règles et contrats d'API, pas la qualité générale des modèles.

Les tests n'ont pas pu être exécutés dans l'environnement de rédaction : Django n'y est pas installé hors du conteneur. Aucun score de précision, rappel, MRR, latence ou taux de faux positifs n'est actuellement mesuré. Les résultats des tests ne doivent donc pas être présentés comme une validation de production.

Protocole recommandé

Axe	Jeu de test / mesure
Extraction	10-20 dossiers fictifs annotés; exactitude par champ (date, lieu, contrat, immatriculation, montant), taux de champs inventés et pièces manquantes.
RAG	15-20 questions, pages attendues; Recall@5, MRR, exactitude des citations et taux d'abstention lorsque les Conditions particulières manquent.
Vision	Photos annotées par zone et type de dommage; macro-F1, précision/rappel par zone, performance selon qualité et éclairage.
Fraud/Decision	Cas cohérents, contradictoires, incomplets et hors corpus; matrice de confusion, faux positifs, faux négatifs et taux INVESTIGATE.
Opérations	Par agent et bout en bout : p50/p95, échecs Ollama, replis, reprise n8n, taille des pièces et taux de callback.

Garde-fous d'évaluation

- Ne jamais confondre risk_score avec une probabilité de fraude; échantillonner les décisions et revoir les cas limites.
- Mesurer séparément ACCEPT, INVESTIGATE et REJECT; privilégier l'abstention à une affirmation contractuelle non étayée.
- Fixer une version de modèles, des exemples immuables et une baseline avant toute modification de prompt.

6. Sécurité, limites et conclusion

Mesures déjà présentes

- Inférence LLM et embeddings dirigés vers Ollama local; CORS limité par défaut à l'interface locale; limite de pièces jointes email configurable à 20 MiB; callback final protégé par un jeton dans l'en-tête.

- Les résultats structurés sont validés; le prompt vision interdit l'identification de personnes et demande de ne pas conclure à une fraude.

Risques observés dans le code de démonstration

- DEBUG est activé par défaut; SECRET_KEY et jeton callback ont des valeurs de développement par défaut; les identifiants Postgres de Compose sont fixes.

- Aucune permission DRF explicite ni authentification par rôle n'est définie; endpoints internes Document/Vision/Policy et lecture du dossier ne doivent pas être exposés tels quels.

- Les médias sont stockés sous MEDIA_ROOT sans chiffrement, scan antivirus ou politique de rétention visible. Les pièces email peuvent sortir de l'environnement local.

- Le contenu d'un document est non fiable et peut contenir une injection de prompt; la validation JSON ne neutralise pas les instructions cachées.

Avant toute exposition réelle

Priorité	Action sécurité
P0	DEBUG=false; secrets forts uniques hors dépôt; rotation du jeton; mots de passe Postgres dédiés; HTTPS et hôtes autorisés explicites.
P0	Authentification et rôles (gestionnaire/admin), permissions DRF; protéger endpoints internes et webhook n8n; journaliser qui consulte/transmet.
P1	Validation MIME/type/taille, antivirus, stockage privé et chiffré, sauvegarde/rétention; limiter données exposées au modèle et aux emails.
P1	Traiter les pièces comme données, jamais comme instructions; exiger citations contractuelles vérifiables; revue humaine avant décision adverse.

Conclusion

Le prototype démontre une architecture locale et explicable pour trier un dossier multimodal. Ses points forts sont l'orchestration hybride, les traces structurées et l'abstention contractuelle. Sa validation reste à construire : jeu d'évaluation annoté, mesure des faux positifs, sécurité d'accès et durcissement de la configuration sont les étapes prioritaires.

Repères de code : backend/claims/agents.py, views.py, services.py, tests.py; backend/claims/policy_corpus.json; n8n/ai-claims-workflow.json; docker-compose.yml.

Annexe A - Bibliothèque de prompts

Convention

Les trois prompts ci-dessous sont les consignes actuellement utilisées côté serveur. Ils sont versionnés ici pour audit pédagogique; la température de génération est 0 et les sorties sont contraintes par un schéma Pydantic. Fraud et Decision ne possèdent pas de prompt : leurs règles sont détaillées en annexe A4.

A1. Document Agent - extraction de faits

Rôle : convertir le formulaire, les textes PDF et la transcription audio en faits structurés sans inventer. Le backend extrait le texte PDF avec pypdf, puis concatène les pièces textuelles et la transcription Whisper.

Prompt système exact

```
Extrais les faits du sinistre. N'invente rien; utilise null ou une liste vide si une donnée manque.
```

Schéma de sortie

Champ	Type / usage
incident_date, location, description, policy_number	Chaînes; faits principaux du dossier.
vehicle_registration	Chaîne ou null; immatriculation extraite.
parties	Liste de chaînes; parties mentionnées.
declared_amount	Nombre ou null; montant déclaré.
missing_documents, extraction_notes	Listes; pièces signalées absentes et notes d'extraction.

Échec observé / correctif

Le repli sans Ollama ne lit pas les PDFs : il reprend les champs du formulaire et marque missing_documents uniquement lorsqu'aucun document n'est joint. Les PDFs scannés ne bénéficient pas actuellement d'un OCR réel. Pour la suite : tests d'extraction par champ, OCR séparé, et distinguer « fichier absent » de « contenu illisible ».

Annexe A - Bibliothèque de prompts (suite)

A2. Vision Agent - analyse des dommages

Rôle : décrire les éléments visibles dans jusqu'à six photos; ne pas identifier de personne et ne pas conclure à une fraude. Le VLM reçoit les images, tandis que le résultat doit normaliser les zones pour les règles aval.

Prompt système exact

```
Inspecte seulement ce qui est visible. N'identifie personne et ne conclus jamais à une fraude. Réponds en français. Lis aussi les textes utiles visibles (OCR). damaged_areas doit contenir une ou plusieurs zones normalisées parmi rear, front, left, right, rear-left, rear-right, front-left, front-right. severity: low, medium, high ou unknown.
```

Schéma de sortie

Champ	Type / contrainte
visible_damage	Booléen.
damaged_areas	Liste de zones normalisées; alias français convertis ensuite.
damage_types	Liste de types de dommages.
severity	low, medium, high ou unknown.
image_quality, observations, confidence	Qualité, observations libres et confiance entre 0 et 1.

Échec observé / correctif

Le fallback local déduit front/rear à partir du récit au lieu d'observer l'image. Une contradiction photo/récit n'est alors pas testée visuellement et peut disparaître. Le workflow doit marquer clairement le moteur utilisé; correction recommandée : si le VLM est indisponible, renvoyer zone inconnue et diminuer la confiance, jamais simuler une observation.

Évaluation attendue

Annoter les photos par zone et sévérité, mesurer macro-F1 et taux de zones inconnues, puis tester images floues, angles incomplets, faible éclairage et photos sans dommage visible.

Annexe A - Bibliothèque de prompts (suite)

A3. Policy/RAG Agent - vérification contractuelle

Rôle : répondre seulement à partir des passages top 5 récupérés du corpus local et signaler les informations individuelles manquantes. La requête contient récit, date, lieu et thèmes de garantie recherchés.

Prompt système exact

```
Vérifie la couverture uniquement avec les extraits contractuels AXA fournis. Cherche en priorité dommages au véhicule, collision et dommages tous accidents. coverage_status: covered uniquement si la garantie souscrite est confirmée; excluded uniquement si une exclusion explicite correspond au sinistre; sinon insufficient_information. Les garanties dépendent aussi des Conditions particulières : si elles manquent ou si le pays du contrat ne correspond pas au dossier, réponds insufficient_information. Dans applicable_articles, cite les pages sous la forme 'Page 42'.
```

Schéma de sortie

Champ	Type / usage
coverage_status	covered / excluded / insufficient_information; autres variantes normalisées.
applicable_articles	Liste de références page normalisées, par exemple Page 34.
explanation	Justification courte fondée sur le contexte fourni.
missing_information	Liste des informations contractuelles manquantes.
confidence	Nombre entre 0 et 1; conservé pour traçabilité.

Échec observé / correctif

Le corpus est AXA France uniquement. Une garde de cohérence force insufficient_information pour les dossiers identifiés comme tunisiens. Le fallback lexical retrouve des pages mais ne confirme jamais la couverture. Les conditions individuelles manquent; la réponse doit donc s'abstenir. Évaluer la récupération avec pages de référence avant de comparer des stratégies de découpage.

Limite importante

La confiance du Policy Agent est produite mais n'est pas utilisée par Decision Agent; Decision ne lit que coverage_status, références et explication. Il faut calibrer et intégrer cette confiance avec prudence, sans la présenter comme probabilité garantie.

Annexe A - Bibliothèque de règles (suite)

A4. Fraud et Decision - règles, pas de prompts LLM

Ces composants sont des fonctions Python déterministes. Les documenter dans la bibliothèque évite de prétendre qu'ils utilisent un prompt ou un modèle génératif.

Agent	Règle implémentée	Effet
Fraud	Description et zone visuelle disjointes (avant contre arrière).	+50, sévérité high.
Fraud	Document Agent signale une pièce manquante.	+25, sévérité medium.
Fraud	Somme des règles.	min(100, somme); aucun bonus négatif pour cohérence.
Decision	Policy = excluded.	REJECT.
Decision	Policy = insufficient_information ou risque > 0.	INVESTIGATE.
Decision	Couverture covered et risque nul.	ACCEPT.

Calcul de confiance

Base 0,95. Pénalités : -0,18 si document manquant; -0,12 sans photo exploitable; -0,20 si couverture inconnue; et -(risk_score/100 x 0,25). Résultat borné entre 0,45 et 0,95. Exemple : couverture inconnue, photos présentes, dossier complet, risque 50 donne 0,95 - 0,20 - 0,125 = 0,625, soit 62,5 %. Ce score est une heuristique, pas une probabilité statistique calibrée.

Limites/faux positifs

- Une mention négative du type « aucun dégât arrière » contient le mot arrière et peut faire ajouter la zone rear au récit. Les mots-clés actuels ne comprennent pas correctement la négation.

- Les seules règles de risque actives sont localisation contradictoire et document manquant; les incohérences de dates, montant ou doublons ne sont pas implémentées.

- Tout risque non nul mène à INVESTIGATE; aucune décision de rejet ne vient du seul score de fraude.

Pistes de correction

Extraire les zones déclarées avec négation structurée; ajouter une règle uniquement après annotation et mesure du taux de faux positifs; tester les frontières de seuil et conserver les preuves textuelles/visuelles pour chaque score.